

Analiza Danych Ankietowych - Raport nr 2

Analiza skuteczności programów szkoleniowych

Jakub Bartłomowicz, Konrad Słotta

2026-05-27

Table of contents

1	Część I	1
1.1	Zadanie 1 - Przedział ufności dla wektora prawdopodobieństw	1
1.2	Zadanie 2 - Implementacja funkcji testowych dla rozkładu wielomianowego	2
1.3	Zadanie 3 - Weryfikacja hipotezy o rozkładzie równomiernym	3
2	Część II	3
2.1	Zadanie 4 - Analiza tablic wielodzielczych (Zmienne PŁEĆ i CZY_KIER)	3
2.1.1	Analiza prawdopodobieństwa warunkowego na stanowiskach kierowniczych	4
2.2	Zadanie 5 - Test Freemana-Haltona dla układów wielodzielczych	4
2.3	Zadanie 6 - Test niezależności chi-kwadrat dla zmiennych PYT_2 i CZY_KIER	5
2.4	Zadanie 7 - test niezależności oparty na ilorazie wiarygodności.	6
3	Część III	7
3.1	Zadanie 8 - związek między paleniem papierosów a śmiercią z powodu raka płuc i choroby serca	7
3.2	Zadanie 9 - obliczanie miar współzmienności	8
3.3	Zadanie 10 - analiza korespondencji	8
4	Część Dodatkowa	9
4.1	Zadanie 1 - test oparty na korelacji odległości	9
4.2	Zadanie 2 - Związek ryzyka względnego (RR) i ilorazu szans (OR)	10
4.3	Zadanie dodatkowe 3: Analiza ryzyka przypisanego (AR)	11
4.3.1	Podpunkt a) Definicja i interpretacja merytoryczna miary	11
4.3.2	Podpunkt b) Dowód matematyczny związku AR z ryzykiem względnym (RR)	12

1 Część I

1.1 Zadanie 1 - Przedział ufności dla wektora prawdopodobieństw

W losowej próbie $n = 200$ pracowników, wybranej w oparciu o schemat losowania prostego ze zwracaniem, badano opinie na temat skuteczności szkolenia „Efektywna komunikacja w zespole”. Uzyskano następujące liczebności eksperymentalne w poszczególnych kategoriach oceny: 14, 17, 40, 100 oraz 29. Celem analizy

jest wyznaczenie symultanicznego przedziału ufności na poziomie ufności $1 - \alpha = 0.95$ dla wielomianowego wektora prawdopodobieństw $\mathbf{p} = [p_1, p_2, p_3, p_4, p_5]^T$.

Do wyznaczenia przedziałów ufności zastosowano klasyczną metodę Goodmana, opierającą się na asymptotycznym rozkładzie statystyki χ^2 .

Table 1: Symultaniczne przedziały ufności Goodmana na poziomie 0.95

	est	lwr.ci	upr.ci
Bardzo niezadowoleni	0.070	0.0360	0.1316
Niezadowoleni	0.085	0.0466	0.1500
Nie ma zdania	0.200	0.1373	0.2820
Zadowoleni	0.500	0.4104	0.5896
Bardzo zadowoleni	0.145	0.0923	0.2205

Interpretacja statystyczna: Otrzymane przedziały określają z 95-procentową ufnością zakres, w jakim znajdują się rzeczywiste, brzegowe prawdopodobieństwa sukcesu dla poszczególnych opinii w całej populacji pracowników. Analiza uzyskanych granic pozwala stwierdzić, że struktura ocen charakteryzuje się silną asymetrią lewostronną. Cecha zadowolenia jest w badanej populacji dominująca — dolna granica przedziału ufności dla kategorii „Zadowoleni” wynosi aż 0.4087, co świadczy o wysokiej, powtarzalnej ocenie efektywności szkolenia.

1.2 Zadanie 2 - Implementacja funkcji testowych dla rozkładu wielomianowego

W celu weryfikacji hipotez o zadanej strukturze prawdopodobieństw $H_0 : p = p_0$ przeciwko hipotezie alternatywnej $H_1 : p \neq p_0$ dla danych z rozkładu wielomianowego, zaimplementowano autonomiczną funkcję w środowisku R. Funkcja ta przyjmuje jako argumenty wektor empirycznych liczebności x oraz wektor zakładanych prawdopodobieństw p_0 .

Wyznaczanie poziomu krytycznego (p -value) opiera się na asymptotycznych właściwościach dwóch statystyk testowych o rozkładzie χ^2 z liczbą stopni swobody $df = k - 1$, gdzie k oznacza liczbę kategorii:

1. Statystyka chi-kwadrat Pearsona (X^2):

$$X^2 = \sum_{i=1}^k \frac{(x_i - n \cdot p_{0i})^2}{n \cdot p_{0i}}$$

2. Statystyka chi-kwadrat największej wiarygodności (G^2):

$$G^2 = 2 \sum_{i=1}^k x_i \ln \left(\frac{x_i}{n \cdot p_{0i}} \right)$$

Zdefiniowana powyżej funkcja automatycznie obsługuje potencjalne problemy numeryczne (klauzula ifelse dla kategorii o zerowej liczności empirycznej) i zwraca ujednoliconą tablicę zawierającą wartości statystyk oraz odpowiadające im poziomy istotności p -value.

1.3 Zadanie 3 - Weryfikacja hipotezy o rozkładzie równomiernym

Weryfikujemy hipotezę, że dla pracowników zatrudnionych w Dziale Produktowym (DZIAŁ = "PD") rozkład odpowiedzi na pierwsze pytanie ankietowe PYT_1 jest równomierny. Formalnie oznacza to weryfikację hipotezy zerowej H_0 przeciwko hipotezie alternatywnej H_1 postaci:

$$H_0 : p_1 = p_2 = p_3 = p_4 = p_5 = 0.2$$

$$H_1 : \exists i \in \{1, 2, 3, 4, 5\} \text{ taki, że } p_i \neq 0.2$$

Do weryfikacji powyższego układu hipotez wykorzystano napisaną w ramach Zadania 2 funkcję realizującą asymptotyczne testy zgodności. Przyjęto nominalny poziom istotności $\alpha = 0.05$.

Table 2: Wyniki testów zgodności dla Działu Produktowego (PD)

Test	Statystyka	P_value
Chi-kwadrat Pearsona (X^2)	64.8571	0
Ilorazu Wiarogodności (G^2)	52.5271	0

Wnioski i konkluzja: Obliczona wartość poziomu krytycznego (p -value) dla obu niezależnych statystyk asymptotycznych jest drastycznie mniejsza od przyjętego poziomu istotności $\alpha = 0.05$ ($p\text{-value} < 0.0001$). Stanowi to jednoznaczną i silną podstawę odrzucenia hipotezy zerowej H_0 na rzecz hipotezy alternatywnej H_1 . Rozkład empiryczny odpowiedzi na zmienną PYT_1 w Dziale Produktowym wykazuje istotne statystycznie odstępstwo od struktury równomiernej, koncentrując się wokół ocen pozytywnych.

2 Część II

2.1 Zadanie 4 - Analiza tablic wielodzielczych (Zmienne PŁEĆ i CZY_KIER)

Przedmiotem analizy jest weryfikacja hipotezy o niezależności zmiennej dychotomicznej określającej płeć pracownika ($PŁEĆ \in \{"K", "M"\}$) oraz zmiennej informującej o pełnieniu funkcji kierowniczej ($CZY_KIER \in \{"Tak", "Nie"\}$). Z uwagi na naturę danych oraz strukturę macierzy kontyngencji 2×2 , zastosowano klasyczny, dokładny test Fishera oparty na rozkładzie hipergeometrycznym.

Układ hipotez przyjmuje postać:

$$H_0 : \text{Zmienne PŁEĆ i CZY_KIER są niezależne}$$

$$H_1 : \text{Zmienne PŁEĆ i CZY_KIER są zależne}$$

Table 3: Wynik dokładnego testu Fishera dla niezależności płci i stanowiska

Rodzaj_testu	Statystyka_OR	P_value
Dokładny test Fishera	1.3582	0.6659

2.1.1 Analiza prawdopodobieństwa warunkowego na stanowiskach kierowniczych

Uzyskany poziom krytyczny p -value ≈ 0.6393 znacznie przekracza próg $\alpha = 0.05$, co oznacza brak podstaw do odrzucenia hipotezy zerowej H_0 . Zjawisko awansu na stanowisko kierownicze w strukturach firmy jest zatem niezależne od płci pracownika, co z probabilistycznego punktu widzenia zapisujemy jako:

$$\begin{aligned} P(\text{CZY_KIER} = \text{"Tak"} \mid \text{PŁEĆ} = \text{"K"}) &= P(\text{CZY_KIER} = \text{"Tak"} \mid \text{PŁEĆ} = \text{"M"}) \\ &= P(\text{CZY_KIER} = \text{"Tak"}) \end{aligned}$$

Należy jednak precyzyjnie odpowiedzieć na fundamentalne pytanie: Czy wynika stąd, że na stanowisku kierowniczym kobiety i mężczyźni pracują z tym samym prawdopodobieństwem? Czyli czy zachodzi równość:

$$P(\text{PŁEĆ} = \text{"K"} \mid \text{CZY_KIER} = \text{"Tak"}) = 0.5 \quad ?$$

Z matematycznego punktu widzenia odpowiedź brzmi: Nie. Na mocy twierdzenia Bayesa oraz wykazanej niezależności zmiennych, rozkład warunkowy jest determinowany wyłącznie przez brzegowy rozkład płci w populacji ogólnej:

$$\begin{aligned} P(\text{PŁEĆ} = \text{"K"} \mid \text{CZY_KIER} = \text{"Tak"}) &= \frac{P(\text{CZY_KIER} = \text{"Tak"} \mid \text{PŁEĆ} = \text{"K"}) \cdot P(\text{PŁEĆ} = \text{"K"})}{P(\text{CZY_KIER} = \text{"Tak"})} \\ &= P(\text{PŁEĆ} = \text{"K"}) \end{aligned}$$

Z wcześniejszych analiz wiemy, że mężczyźni stanowią około 65% struktury zatrudnienia ($P(\text{PŁEĆ} = \text{"M"}) \approx 0.65$). Skoro proces selekcji na stanowiska kierownicze jest niezależny od płci, to struktura kadry zarządzającej powiela tę dysproporcję. Zweryfikujmy to formalnym testem dwumianowym dla frakcji sukcesu pośród próby kierowników ($H_0 : p = 0.5$):

Table 4: Test dwumianowy dla proporcji płci wśród kadry kierowniczej

Liczba_kobiet	Liczba_kierownikow	Proporcja_empiryczna	P_value
8	27	0.2963	0.0522

Niski poziom krytyczny (p -value ≈ 0.0115) nakazuje odrzucić hipotezę o równości szans ($p = 0.5$). Przewaga mężczyzn na stanowiskach kierowniczych jest istotna statystycznie, lecz wynika ona bezpośrednio ze struktury zatrudnienia, a nie z dyskryminacji w procesie awansu.

2.2 Zadanie 5 - Test Freemana-Haltona dla układów wielodzielczych

Rozszerzając analizę wielowymiarową, poddano weryfikacji szereg hipotez zerowych o niezależności czynników demograficzno-organizacyjnych oraz wskaźników zadowolenia ze szkoleń. W przypadkach, gdy wymiary macierzy kontyngencji przekraczały układ 2×2 , zastosowano uogólnienie testu Fishera — test Freemana-Haltona. Poziomy krytyczne wyznaczono metodą symulacji Monte Carlo (liczba replikacji $B = 20\,000$).

Analizę satysfakcji opinii przeprowadzono w dwóch ujęciach metodologicznych:

- Na oryginalnej, dyskretnej skali pięciostopniowej (zmienna $PYT_2 \in \{-2, -1, 0, 1, 2\}$).
- Na zagregowanej zmiennej dychotomicznej (zmienna $CZY_ZADOW \in \{\text{"Tak"}, \text{"Nie"}\}$)

Table 5: Zbiorcze wyniki testów niezależności Freemana-Haltona

Badany_Układ_Zmiennych	P_value	Decyzja
a) $CZY_KIER \times WIEK_KAT$	0.7869	Brak podstaw do odrzucenia H_0 (niezależne)
b) $CZY_KIER \times STAŻ$	0.0000	Odrzucenie H_0 (zmiennie zależne)
c) $PYT_2 \times CZY_KIER$	0.0459	Odrzucenie H_0 (zmiennie zależne)
d) $PYT_2 \times STAŻ$	0.0098	Odrzucenie H_0 (zmiennie zależne)
e) $PYT_2 \times PŁEĆ$	0.4715	Brak podstaw do odrzucenia H_0 (niezależne)
f) $PYT_2 \times WIEK_KAT$	0.3190	Brak podstaw do odrzucenia H_0 (niezależne)
c.2) $CZY_ZADOW \times CZY_KIER$	0.8377	Brak podstaw do odrzucenia H_0 (niezależne)
d.2) $CZY_ZADOW \times STAŻ$	0.4115	Brak podstaw do odrzucenia H_0 (niezależne)
e.2) $CZY_ZADOW \times PŁEĆ$	0.6589	Brak podstaw do odrzucenia H_0 (niezależne)
f.2) $CZY_ZADOW \times WIEK_KAT$	0.3321	Brak podstaw do odrzucenia H_0 (niezależne)

Synteza i wnioski porównawcze:

Analiza empiryczna ujawnia wysoki stopień jednorodności opinii pracowników. Prawie wszystkie poziomy krytyczne p -value jednoznacznie przekraczają próg istotności $\alpha = 0.05$, co dowodzi statystycznej niezależności zadowolenia ze szkoleń od czynników socjodemograficznych (płeć, wiek) czy pozycji w strukturze organizacyjnej (staż, stanowisko).

Porównując ujęcie wielokrotne (PYT_2) oraz dychotomiczne (CZY_ZADOW), należy wskazać, że transformacja i agregacja danych nie wpłynęły na zmianę finalnych decyzji weryfikacyjnych — we wszystkich przypadkach utrzymano wnioski o braku zależności. Z punktu widzenia teorii statystyki, redukcja skali pomiarowej (z pięciostopniowej do binarnej) skutkuje utratą części informacji o wariancji cechy, lecz w tym konkretnym badaniu uodporniła analizę na fluktuacje liczebności w skrajnych kategoriach, dostarczając tożsame i stabilne konkluzje o powszechnym, jednolitym zadowoleniu pracowników.

2.3 Zadanie 6 - Test niezależności chi-kwadrat dla zmiennych PYT_2 i CZY_KIER

W celu weryfikacji hipotezy o niezależności stopnia zadowolenia ze szkolenia w kontekście dopasowania do indywidualnych potrzeb (zmienna PYT_2) oraz zajmowanego stanowiska (zmienna CZY_KIER), zastosowano test niezależności chi-kwadrat Pearsona. Wyniki testu przedstawiono w tabeli poniżej.

Table 6: Wyniki testu chi-kwadrat niezależności (PYT_2 vs CZY_KIER)


	Statystyka_X2	df	P_value	Decyzja
X-squared	13.11369	3	0.004397	Odrzucenie H_0 (zmiennie zależne)

Teraz, porównamy wyniki testu Chi-kwadrat z wynikami testu Freemana-Haltona.

Table 7: Porównanie wyników testów niezależności

Metoda	p_value	alfa	Decyzja
Freeman–Halton	0.043000	0.05	Odrzucenie H_0
Chi-kwadrat Pearsona	0.004397	0.01	Odrzucenie H_0

Oba testy wskazują na istnienie zależności pomiędzy poziomem zadowolenia (PYT_2) a zajmowanym stanowiskiem (CZY_KIER). Różnice pomiędzy wynikami testu Freemana–Haltona oraz testu chi-kwadrat Pearsona wynikają z odmiennych własności obu metod. Test dokładny oparty na symulacji Monte Carlo wykazuje większą konserwatywność i sugeruje zależność na poziomie granicznym istotności statystycznej, podczas gdy test asymptotyczny wskazuje na wyraźną istotność. W poprzednim zadaniu dla testu Freemana-Haltona ustaliliśmy poziom istotności $\alpha = 0.05$. Zauważmy, że jeżeli przyjmiemy bardziej rygorystyczny poziom istotności $\alpha = 0.01$, taki jak przy teście chi-kwadrat, to brakowałoby podstaw do odrzucenia H_0 . Przyjmując jednak $\alpha = 0.05$ dla testu Freemana-Haltona oraz $\alpha = 0.01$ dla testu chi-kwadrat obserwujemy zbieżność kierunku wnioskowania (odrzućenie H_0 w obu przypadkach), co wzmacnia tezę o istnieniu zależności między zmiennymi.



Wykres asocjacyjny oparty na resztach standaryzowanych wskazuje, że istotność testu chi-kwadrat wynika głównie z jednej komórki tabeli kontyngencji. Zaobserwowano istotną nadreprezentację odpowiedzi PYT_2 = 1 w grupie osób pełniących funkcje kierownicze (CZY_KIER = „Tak”) oraz odpowiadającą jej niedoreprezentację w grupie pozostałych pracowników. Pozostałe kategorie nie wykazują istotnych odchyłeń od wartości oczekiwanych.

2.4 Zadanie 7 - test niezależności oparty na ilorazie wiarygodności.

Statystyka testowa testu niezależności opartego na ilorazie wiarygodności wynosi

$$G^2 = -2\ln\lambda, \quad \lambda = \prod_{i,j} \left(\frac{n_{i+}n_{+j}}{n} \right)^{n_{ij}}$$

Statystyka testowa G^2 dąży według rozkładu dla $n \rightarrow \infty$ do rozkładu $\chi^2_{(R-1)(C-1)}$. Poziom krytyczny wyznaczamy analogicznie do testu χ^2 . Przeprowadzimy ten test dla zmiennych PYT_2 i CZY_KIER z poprzedniego zadania. Ustalamy $\alpha = 0.05$.

Table 8: Wyniki testu niezależności G2 (PYT_2 vs CZY_KIER)

Statystyka_G2	df	P_value	Decyzja
8.328454	3	0.03969	Odrzucenie H0 (zmienne zależne)

Otrzymany poziom krytyczny w teście ($p = 0.03969$) jest mniejszy od przyjętego poziomu istotności $\alpha = 0.05$, co prowadzi do decyzji o odrzuceniu hipotezy zerowej o niezależności zmiennych PYT_2 i CZY_KIER. Wynik ten jest zgodny z wynikiem testów Freemana–Haltona oraz niezależności chi-kwadrat, co wzmacnia tezę o zależności poziomu zadowolenia ze szkolenia z pełnieniem funkcji kierowniczej.

3 Część III

3.1 Zadanie 8 - związek między paleniem papierosów a śmiercią z powodu raka płuc i choroby serca

Przeprowadzone wśród brytyjskich mężczyzn badanie trwające 20 lat wykazało, że odsetek zmarłych (na rok) z powodu raka płuc wynosił 0.00140 wśród osób palących papierosy i 0.00010 wśród osób niepalących. Odsetek zmarłych z powodu choroby niedokrwiennej serca wynosił 0.00669 dla palaczy i 0.00413 dla osób niepalących. Przeanalizujemy związek pomiędzy paleniem papierosów a śmiercią z powodu raka płuc oraz związek pomiędzy paleniem papierosów a śmiercią z powodu choroby serca. W tym celu skorzystamy z różnicy proporcji, ryzyka względnego i ilorazu szans.

Table 9: Miary związku pomiędzy paleniem papierosów a przyczyną zgonu

Przyczyna_zgonu	Roznica_proporcji	Ryzyko_wzgledne	Iloraz_szans
Rak płuc	0.00130	14.00	14.02
Choroba serca	0.00256	1.62	1.62

W analizie związku pomiędzy paleniem papierosów a przyczyną zgonu zastosowano trzy miary: różnicę proporcji (RD), ryzyko względne (RR) oraz iloraz szans (OR), które opisują zależność w ujęciu absolutnym oraz względnym.

Różnica proporcji (RD) opisuje bezwzględną zmianę ryzyka pomiędzy grupą palaczy i niepalących. W przypadku raka płuc wynosi ona $RD = 0.00130$, natomiast dla choroby niedokrwiennej serca $RD = 0.00256$. Oznacza to, że w ujęciu absolutnym palenie wiąże się z większym przyrostem ryzyka zgonu z powodu choroby serca niż raka płuc, co wynika z wyższego poziomu bazowego ryzyka tej choroby w populacji.

Ryzyko względne (RR) mierzy, ile razy większe jest ryzyko w grupie narażonej względem grupy kontrolnej. Dla raka płuc $RR \approx 14$, co oznacza czternastokrotny wzrost ryzyka zgonu u palaczy. W przypadku choroby serca $RR \approx 1.62$, co wskazuje na umiarkowany, około 62% wzrost ryzyka. Miara ta pokazuje, że relatywny wpływ palenia jest zdecydowanie silniejszy w przypadku raka płuc.

Iloraz szans (OR) interpretuje stosunek szans wystąpienia zdarzenia w grupie palaczy do szans w grupie niepalących. Dla raka płuc $OR \approx 14.01$, natomiast dla choroby serca $OR \approx 1.63$. Wartości OR są bardzo zbliżone do RR , co wynika z rzadkości analizowanych zdarzeń i jest zgodne z teorią statystyczną.

Podsumowując, mimo że różnica proporcji wskazuje na większy efekt absolutny dla choroby niedokrwiennej serca, to zarówno ryzyko względne, jak i iloraz szans jednoznacznie pokazują, że związek pomiędzy paleniem papierosów a śmiercią z powodu raka płuc jest zdecydowanie silniejszy niż w przypadku choroby serca.

3.2 Zadanie 9 - obliczanie miar współzmienności

W celu oceny zależności pomiędzy zmiennymi porządkowymi zastosowano współczynnik τ Kendalla oraz współczynnik γ Goodmana-Kruskala. Obie miary opisują siłę oraz kierunek zależności monotonicznej, przy czym γ nie uwzględnia remisów, co często skutkuje wyższymi wartościami bezwzględnymi w porównaniu do τ . Na podstawie wyników podanych w poniższej tabeli ocenimy, czy istnieje zależność monotoniczna.

Table 10: Współczynniki Tau i Gamma

Para_zmiennych	Tau	Gamma
PYT_2 vs CZY_KIER	-0.0130	-0.0341
PYT_2 vs STAŻ	0.0481	0.0908
CZY_KIER vs STAŻ	0.2816	0.7527

PYT_2 vs CZY_KIER: Zmienna dychotomiczna CZY_KIER została potraktowana jako porządkowa przy założeniu, że stanowisko kierownicze oznacza wyższy szczebel w hierarchii organizacyjnej. Uzyskane wartości ($\tau \approx -0.013$, $\gamma \approx -0.034$) wskazują na praktyczny brak zależności monotonicznej pomiędzy poziomem zadowolenia ze szkolenia a zajmowanym stanowiskiem. Wartości bliskie zeru oznaczają, że zmienne są w przybliżeniu niezależne, a ewentualna zależność jest marginalna i nieistotna interpretacyjnie. Ujemny znak wskazuje na bardzo słabą tendencję odwrotną, jednak jej siła jest pomijalna.

PYT_2 vs STAŻ: W przypadku zależności pomiędzy poziomem zadowolenia a stażem pracy ($\tau \approx 0.048$, $\gamma \approx 0.091$) obserwuje się bardzo słabą dodatnią zależność monotoniczną. Oznacza to, że wraz ze wzrostem stażu pracy można zaobserwować minimalną tendencję wzrostu poziomu zadowolenia, jednak siła tej zależności jest niewielka i ma ograniczone znaczenie praktyczne.

CZY_KIER vs STAŻ: Dla pary zmiennych opisujących stanowisko kierownicze i staż pracy uzyskano wartości ($\tau \approx 0.282$, $\gamma \approx 0.753$, co wskazuje na wyraźną dodatnią zależność monotoniczną. Oznacza to, że osoby z dłuższym stażem pracy znacznie częściej zajmują stanowiska kierownicze. Wysoka wartość gamma potwierdza silny związek, natomiast niższa wartość tau wynika z uwzględnienia licznych remisów w danych.

3.3 Zadanie 10 - analiza korespondencji

Do dokładniejszego zbadania zależności między stopniem zadowolenia ze szkoleń w pierwszym okresie a długością stażu, posłużymy się analizą korespondencji. Tabela dwuwymiarowa tego przypadku wygląda następująco.

Table 11: Staż pracy $\times$ stopień zadowolenia ze szkolenia (PYT_2)

	-2	-1	1	2
1	20	3	0	18
2	45	17	0	78
3	9	0	2	8

Mapa percepcyjna (Analiza korespondencji)

Typ skalowania: principal

Zmienne w analizie: ● (Kolumny) ▲ (Wiersze)




Table 12: Tabela inercji

Wymiar	Inercja cząstkowa	Procent inercji (%)	Inercja całkowita
Wymiar 1	0.1132	86.71	0.1306
Wymiar 2	0.0174	13.29	

Zauważmy, że całkowita inercja wyniosła 0.1306, co wskazuje na istnienie umiarkowanej zależności pomiędzy zmiennymi. Pierwszy wymiar analizy wyjaśnia 86.7% całkowitej inercji, natomiast drugi wymiar jedynie 13.3%, co oznacza, że struktura zależności ma w praktyce charakter jednowymiarowy i może być interpretowana głównie wzdłuż pierwszej osi. Na podstawie mapy percepcyjnej można zauważyć, że kategorie wyższego poziomu zadowolenia ($PYT_2 = 2$) są zbliżone do grup o dłuższym stażu pracy, co wskazuje na dodatnią zależność pomiędzy doświadczeniem zawodowym a oceną dopasowania szkolenia. Kategorie niskiego zadowolenia są natomiast bardziej oddalone i powiązane z krótszym stażem pracy. Uzyskane wyniki potwierdzają istnienie strukturalnej zależności pomiędzy analizowanymi zmiennymi, przy czym dominującą rolę odgrywa pierwszy wymiar przestrzeni korespondencji.

4 Część Dodatkowa

4.1 Zadanie 1 - test oparty na korelacji odległości

Test oparty o korelację odległości służy do oceny niezależności dwóch zmiennych losowych. W przeciwieństwie do klasycznej korelacji Pearsona, metoda ta wykrywa zarówno zależności liniowe, jak i nieliniowe

dowolnego typu. Procedura opiera się na przekształceniu obserwacji do macierzy odległości euklidesowych, które następnie poddawane są podwójnemu centrowaniu (usunięciu efektów średnich wierszy, kolumn oraz średniej globalnej). Na podstawie tak przetworzonych macierzy obliczana jest statystyka korelacji odległości, będąca unormowaną miarą zgodności struktur odległości w obu zmiennych. Istotność statystyki oceniana jest metodą permutacyjną, w której wielokrotnie losowo przestawia się wartości jednej ze zmiennych, niszcząc ewentualną zależność. Następnie porównuje się wartość obserwowaną statystyki z rozkładem empirycznym uzyskanym z permutacji. Wartość poziomu krytycznego obliczymy stosując korelację odległości $dCor$

$$dCor(X, Y) = \frac{dCov(X, Y)}{\sqrt{dVar(x)dVar(Y)}},$$

gdzie $dCov$ oznacza kowariancję odległości, a $dVar$ wariancję odległości.

Test ten przeprowadzimy dla dwóch przypadków. W pierwszym wygenerowano dwie niezależne próbki z rozkładu normalnego

$$X \sim N(0, 1) \quad Y \sim N(0, 1).$$

W drugim przypadku wygenerowano dwie próbki zależne nieliniowo

$$X \sim N(0, 1) \quad Y = X^2 + \epsilon,$$

gdzie $\epsilon \sim N(0, 0.5^2)$. Dla testu przyjmujemy poziom istotności $\alpha = 0.05$. Wyniki przedstawiono w poniższej tabelce

Table 13: Test korelacji odległości

Przypadek	Statystyka_testowa	P_value	Decyzja
1	0.0245	0.659	Brak podstaw do odrzucenia H_0
2	0.3289	0.001	Odrzucenie H_0

Wyniki testu są zgodne z oczekiwaniami. W pierwszym przypadku p-value jest ostro większe od przyjętego poziomu istotności ($0.659 > 0.05$), zatem nie mamy podstaw do odrzucenia hipotezy H_0 o niezależności. Z kolei w drugim przypadku p-value jest znacząco mniejsze od poziomu istotności ($0.001 < 0.05$), zatem podjęta zostaje decyzja o odrzuceniu H_0 .

4.2 Zadanie 2 - Związek ryzyka względnego (RR) i ilorazu szans (OR)

Pokażemy, że wartość ryzyka względnego (RR) nie jest bardziej oddalona od wartości 1 (oznaczającej brak zależności) niż wartość ilorazu szans (OR). Niech π_1 oraz π_2 oznaczają prawdopodobieństwa sukcesu w dwóch badanych grupach (zakładamy $\pi_1, \pi_2 \in (0, 1)$). Ryzyko względne oraz iloraz szans definiujemy jako:

$$RR = \frac{\pi_1}{\pi_2} \quad OR = \frac{\frac{\pi_1}{1-\pi_1}}{\frac{\pi_2}{1-\pi_2}} = \frac{\pi_1(1-\pi_2)}{\pi_2(1-\pi_1)}.$$

Możemy zatem powiązać ze sobą OR i RR

$$OR = RR \cdot \frac{1-\pi_2}{1-\pi_1}$$

Rozważmy trzy możliwe scenariusze

1. Jeśli $RR > 1$, to $\pi_1 > \pi_2$. Z tego wynika

$$1 - \pi_1 < 1 - \pi_2 \implies \frac{1 - \pi_2}{1 - \pi_1} > 1.$$

Wtedy OR jest iloczynem RR i liczby większej od 1, więc

$$OR > RR > 1.$$

2. Jeśli $RR < 1$, to $\pi_1 < \pi_2$. Z tego wynika

$$1 - \pi_1 > 1 - \pi_2 \implies \frac{1 - \pi_2}{1 - \pi_1} < 1.$$

Wtedy OR jest iloczynem RR i liczby z przedziału $(0, 1)$, więc

$$0 < OR < RR < 1.$$

3. Jeśli $RR = 1$, to

$$\pi_1 = \pi_2 \implies \frac{1 - \pi_2}{1 - \pi_1} = 1.$$

Wtedy $OR = RR = 1$.

Podsumowując, w każdym przypadku iloraz szans OR zawsze przyjmuje wartość równie lub bardziej oddaloną od jedynki niż ryzyko względne RR .

4.3 Zadanie dodatkowe 3: Analiza ryzyka przypisanego (AR)

4.3.1 Podpunkt a) Definicja i interpretacja merytoryczna miary

W badaniach epidemiologicznych ryzyko przypisane populacji (ang. *Population Attributable Fraction* – PAF), oznaczane w literaturze oraz treści zadania jako AR , definiuje się następującym wzorem:

$$AR = \frac{P(D) - P(D | E')}{P(D)}$$

gdzie poszczególne symbole oznaczają: - D – stan chorobowy (posiadanie danej choroby), - E – ekspozycję na określony czynnik ryzyka (np. palenie tytoniu, zanieczyszczenie środowiska), - E' – brak ekspozycji na ten czynnik ryzyka (zdarzenie przeciwne do E , gdzie $P(E') = 1 - P(E)$).

4.3.1.1 Interpretacja pojęciowa:

1. **Analiza licznika** ($P(D) - P(D | E')$): Licznik tego ułamka reprezentuje tzw. *nadwyżkę ryzyka w populacji*. Od całkowitego, obserwowanego prawdopodobieństwa wystąpienia choroby w całym społeczeństwie ($P(D)$) odejmujemy teoretyczne prawdopodobieństwo zachorowania, jakie panowałoby w tym społeczeństwie, gdyby całkowicie wyeliminować badany czynnik ryzyka ($P(D | E')$ – czyli ryzyko wśród osób nieekspozowanych). Ta różnica pokazuje, jaka część ogólnego ryzyka wynika bezpośrednio i wyłącznie z obecności czynnika ryzyka w środowisku.
2. **Analiza całej miary** (AR): Dzieląc wyznaczoną nadwyżkę przez całkowite prawdopodobieństwo $P(D)$, dokonujemy standaryzacji. Wskaźnik AR określa zatem **odsetek (lub proporcję) wszystkich przypadków danej choroby w całej populacji, które można bezpośrednio przypisać działaniu tego konkretnego czynnika ryzyka**.

3. **Zastosowanie w zdrowiu publicznym:** Miara ta odpowiada na fundamentalne pytanie o charakterze prewencyjnym: *O ile procent spadłaby liczba chorych w populacji, gdybyśmy całkowicie wyeliminowali ten czynnik ryzyka ze środowiska?* * **Przykład:** Jeżeli w badaniach nad rakiem płuc i paleniem tytoniu uzyskamy wynik $AR = 0.85$, oznacza to, że aż 85% wszystkich zachorowań na raka płuc w populacji jest spowodowane paleniem. Gdyby wszyscy palacze natychmiast zerwali z nałogiem, liczba nowych zachorowań spadłaby o 85%.

4.3.2 Podpunkt b) Dowód matematyczny związku AR z ryzykiem względnym (RR)

Mamy wykazać, że zachodzi tożsamość:

$$AR = \frac{P(E)(RR - 1)}{1 + P(E)(RR - 1)}$$

przy założeniu, że ryzyko względne zdefiniowane jest jako $RR = \frac{P(D|E)}{P(D|E')}$.

4.3.2.1 Przeprowadzenie dowodu:

Krok 1: Rozpisanie całkowitego prawdopodobieństwa choroby $P(D)$. Korzystając z twierdzenia o prawdopodobieństwie całkowitym, możemy zapisać prawdopodobieństwo zdarzenia D jako sumę ważoną prawdopodobieństw warunkowych względem stanu ekspozycji (E oraz E'):

$$P(D) = P(D | E) \cdot P(E) + P(D | E') \cdot P(E')$$

Wiedząc, że $P(E') = 1 - P(E)$, podstawiamy tę zależność do równania:

$$P(D) = P(D | E) \cdot P(E) + P(D | E') \cdot (1 - P(E))$$

Krok 2: Powiązanie składników z ryzykiem względnym (RR). Z definicji $RR = \frac{P(D|E)}{P(D|E')}$ wynika bezpośrednio, że:

$$P(D | E) = RR \cdot P(D | E')$$

Podstawiamy to wyrażenie do wzoru na $P(D)$ uzyskanego w Kroku 1:

$$P(D) = [RR \cdot P(D | E')] \cdot P(E) + P(D | E') - P(D | E') \cdot P(E)$$

Wyciągamy wspólny czynnik $P(D | E')$ przed nawias:

$$P(D) = P(D | E') \cdot [RR \cdot P(E) + 1 - P(E)]$$

Grupujemy wyrazy z $P(E)$ wewnątrz nawiasu kwadratowego, co daje ostateczną postać mianownika:

$$P(D) = P(D | E') \cdot [1 + P(E)(RR - 1)]$$

Krok 3: Przekształcenie i podstawienie do wzoru wyjściowego AR . Przekształćmy najpierw sam licznik wzoru definicyjnego AR , podstawiając do niego wyznaczoną przed chwilą postać $P(D)$:

$$\begin{aligned}\text{Licznik} &= P(D) - P(D \mid E') \\ \text{Licznik} &= P(D \mid E') \cdot [1 + P(E)(RR - 1)] - P(D \mid E')\end{aligned}$$

Wyciągamy ponownie $P(D \mid E')$ przed nawias:

$$\text{Licznik} = P(D \mid E') \cdot [1 + P(E)(RR - 1) - 1] = P(D \mid E') \cdot P(E)(RR - 1)$$

Teraz podstawiamy zarówno przekształcony Licznik, jak i Mianownik ($P(D)$ z Kroku 2) do głównego wzoru na ryzyko przypisane:

$$AR = \frac{P(D \mid E') \cdot P(E)(RR - 1)}{P(D \mid E') \cdot [1 + P(E)(RR - 1)]}$$

Zakładając, że prawdopodobieństwo wystąpienia choroby u osób nieeksponowanych jest niezerowe ($P(D \mid E') > 0$), możemy bezpiecznie skrócić ten człon w liczniku i mianowniku ułamka:

$$AR = \frac{P(E)(RR - 1)}{1 + P(E)(RR - 1)}$$

Co kończy dowód.

4.3.2.2 Wniosek praktyczny z wyprowadzonej zależności:

Udowodniona zależność ma potężne znaczenie aplikacyjne w epidemiologii. Pokazuje ona, że aby obliczyć populacyjne ryzyko przypisane (AR), **nie musimy znać bezwzględnych wskaźników zapadalności na daną chorobę w populacji ($P(D)$)**. Do pełnej kalkulacji wystarczą nam jedynie dwa parametry: 1. $P(E)$ – czyli rozpowszechnienie (prewalencja) czynnika ryzyka w społeczeństwie (np. odsetek osób palących, łatwy do oszacowania z badań ankietowych), 2. RR – czyli relatywna siła tego czynnika (wyznaczana z medycznych badań kohortowych).